



Universidade Estadual da Paraíba - UEPB

Campus I

Centro de Ciências e Tecnologia - CCT

Departamento de Computação

Laryssa Finizola Costa da Silva

Mirelle Casimiro Silvino

Pedro Henrique Franca Sales

**Análise Comparativa das Técnicas de Projeto de Algoritmos Aplicadas
ao Problema de Sequência Comum Mais Longa (LCS).**

Campina Grande - PB

Março, 2026

SUMÁRIO

1 INTRODUÇÃO.....	3
1.2 OBJETIVOS.....	4
1.2.1 Geral.....	4
1.2.2 Específicos.....	4
2 METODOLOGIA E IMPLEMENTAÇÃO.....	6
2.1 Estrutura do Sistema Desenvolvido.....	6
3 ALGORITMOS IMPLEMENTADOS.....	8
3.1 Backtracking.....	8
3.1.1 Análise de Corretude.....	10
3.1.2 Análise de Desempenho.....	11
3.1.2.1 Espacial.....	11
3.1.2.2 Temporal.....	12
3.2 Branch and Bound.....	13
3.2.1 Análise de Corretude.....	15
Estratégia de Poda (Branch and Bound).....	17
Condição de poda:.....	18
Garantia de Otimalidade.....	18
3.2.2 Análise de Desempenho.....	18
3.2.2.1 Espacial.....	18
3.2.2.2 Temporal.....	20
3.3 Programação Dinâmica.....	21
3.3.1 Análise de Corretude.....	24
3.3.2 Análise de Desempenho.....	24
3.3.2.1 Espacial.....	25
3.3.2.2 Temporal.....	26
3.4 Estratégia Gulosa.....	27
3.4.1 Análise de Corretude.....	28
3.4.2 Análise de Desempenho.....	29
3.4.2.1 Espacial.....	29
3.4.2.2 Temporal.....	31
4 EXPERIMENTOS E RESULTADOS.....	33
4.1 Instâncias de Teste.....	33
4.2 Resultados Obtidos.....	34
5 ANÁLISE E DISCUSSÃO.....	37
5.1 Comparação das Estratégias.....	37
6 CONCLUSÃO.....	41
7 REFERÊNCIAS.....	43

1 INTRODUÇÃO

O Problema da Maior Subsequência Comum (LCS - *Longest Common Subsequence*) surge da necessidade fundamental de comparar duas sequências para identificar o seu grau de similaridade, preservando a ordem estrutural dos elementos. Tais sequências podem assumir diversas formas, desde cadeias de caracteres em sistemas de texto até sequências moleculares complexas.

Para a correta formulação do problema, é preciso distinguir os conceitos de *substring* e subsequência. Enquanto uma *substring* exige que os caracteres sejam estritamente contíguos e ininterruptos (por exemplo, "cas" na palavra "casa"), uma subsequência permite saltos, exigindo unicamente a manutenção da ordem relativa original dos elementos. Dessa forma, a partir da palavra "casa", é possível extrair subsequências válidas como "ca", "cs" ou "aa". A partir desta premissa, o objetivo central do LCS consiste em determinar a maior sequência de elementos que esteja presente simultaneamente em duas sequências distintas.

A relevância computacional deste problema reflete-se em suas vastas aplicações práticas. O algoritmo é a base de ferramentas que verificam similaridade entre textos (detecção de plágio), sistemas de controle de versão e, de forma proeminente, na área da bioinformática, onde é amplamente utilizado no alinhamento de sequências de DNA e RNA para mapear semelhanças genéticas.

Contudo, encontrar a Maior Subsequência Comum pode ser um desafio computacional custoso, sujeito ao fenômeno da explosão combinatória dependendo da abordagem utilizada.

Por esta razão, o presente relatório tem como objetivo analisar e contrastar quatro estratégias algorítmicas distintas para a resolução do LCS: a busca exaustiva (*Backtracking*), a busca otimizada por poda matemática (*Branch and Bound*), a troca de complexidade espacial por temporal (Programação Dinâmica) e a aproximação heurística de escolha local (Estratégia Gulosa). Através deste comparativo, busca-se demonstrar na prática os *trade-offs* (compromissos) entre tempo de execução, consumo de memória e a garantia de otimização da solução.

1.2 OBJETIVOS

1.2.1 Geral

O objetivo geral deste trabalho é estudar e analisar o Problema da Maior Subsequência Comum (LCS), por meio da implementação e comparação empírica de diferentes abordagens algorítmicas. Busca-se compreender o comportamento computacional destas técnicas na prática, avaliando os *trade-offs* (compromissos) entre tempo, consumo de memória e otimalidade da solução diante do crescimento da entrada (explosão combinatória).

1.2.2 Específicos

- Implementar uma solução analítica para o problema LCS utilizando **Backtracking**, explorando a árvore de espaço de estados a fim de compreender o custo da busca exaustiva pura;
- Implementar uma versão otimizada utilizando a técnica de **Branch and Bound**, introduzindo uma heurística de poda matemática para reduzir o número de estados explorados;
- Implementar uma abordagem baseada em **Programação Dinâmica**, utilizando memorização em matriz para anular a sobreposição de subproblemas e converter a complexidade exponencial em polinomial;
- Implementar uma **Estratégia Gulosa** para avaliar o impacto de decisões locais de baixo custo na qualidade final da solução (comprovação da falha do ótimo local frente ao ótimo global);
- Desenvolver um mecanismo de interrupção segura que aborte a execução ao atingir um limite estipulado (30 segundos), contabilizando a quantidade de nós visitados até o corte para demonstrar a inviabilidade da força bruta em instâncias maiores;
- Analisar rigorosamente a corretude e o desempenho temporal e espacial das soluções implementadas, extraíndo métricas de tempo de execução (ms), uso dinâmico de memória da JVM (MB) e estados avaliados;
- Comparar os resultados obtidos entre as quatro abordagens, submetendo-as a instâncias de teste de complexidade crescente (de 10 a 10.000 caracteres);



- Versionar e documentar o código-fonte desenvolvido, juntamente com as instruções de reprodução (*benchmark*), em um repositório no GitHub.

2 METODOLOGIA E IMPLEMENTAÇÃO

2.1 Estrutura do Sistema Desenvolvido

O projeto foi implementado na linguagem Java, adotando o paradigma de Orientação a Objetos. A arquitetura foi concebida sob os preceitos dos padrões GRASP (*General Responsibility Assignment Software Patterns*), fundamentando-se primordialmente na Alta Coesão e no Baixo Acoplamento. A atribuição de responsabilidades foi desenhada de modo que a lógica de leitura de arquivos, o motor de testes e os algoritmos de resolução operem de forma independente, utilizando o conceito de delegação de tarefas a classes especialistas, sem sobrecarregar as classes de domínio.

Para facilitar a injeção de novos algoritmos sem alterar o motor de testes principal, o sistema aplicou fortemente os princípios de polimorfismo. Na prática, essa arquitetura — que protege o código contra o impacto de mudanças — foi materializada através do padrão de projeto comportamental clássico do catálogo GoF (*Gang of Four*), conhecido como *Strategy*. A organização do código-fonte foi dividida nos seguintes pacotes lógicos:



lcs (Pacote Raiz): Contém a classe *Main*, que atua como o motor de orquestração e *benchmark* do sistema, possuindo um menu interativo para a execução em lote das análises e abrigando todos os seus subpacotes:

- **lcs.model**: Atua como o domínio de dados do sistema. Contém a classe *LCSResult*, que empacota de forma coesa o resultado processado (o comprimento numérico e a *string* da maior subsequência comum) para o tráfego seguro de informações entre as camadas lógicas.
- **lcs.performance**: Centraliza a responsabilidade de monitoramento de métricas e estabilidade. Abriga a classe *PerformanceMetrics*, que atua rastreando o custo computacional (estados avaliados ou iterações) durante a execução e gerenciando o mecanismo de interrupção segura (*timeout*).
- **lcs.reader**: Isola a responsabilidade de entrada e saída (I/O). Possui a classe *LCSReader*, delegada unicamente para ler os arquivos de texto padronizados e extrair as *strings* de teste de forma dinâmica.
- **lcs.strategy**: Representa o núcleo estrutural do padrão comportamental *Strategy*. Ele define o contrato comum através da interface *LCSAlgorithm* e contém as quatro implementações concretas de resolução do problema: as classes *LCSBacktracking*, *LCSBranchAndBound*, *LCSDynamicProgramming* e *LCSGreedy*.

Além da separação em pacotes lógicos, a estrutura de diretórios do projeto segue o padrão convencional da ferramenta de automação Maven (evidenciada pelo arquivo `pom.xml`), dividindo-se em:

- **src/main/resources/**: Diretório destinado ao armazenamento dos recursos estáticos do sistema, utilizado para abrigar as instâncias de teste (arquivos com sequências variando de 10 a 10.000 caracteres).
- **src/test/**: Estrutura espelhada focada em Garantia de Qualidade (QA), dedicada ao armazenamento das suítes de testes unitários automatizados construídos para validar a correção semântica dos algoritmos implementados.

O projeto pode ser acessado no repositório no GitHub:
<https://github.com/laryssa-finizola/lcs-taal>

3 ALGORITMOS IMPLEMENTADOS

3.1 Backtracking

A abordagem de *backtracking* (ou retrocesso) aplicada ao problema da Maior Subsequência Comum (LCS) consiste em uma **estratégia de busca exaustiva**, frequentemente associada à "força bruta". O algoritmo constrói a solução de forma incremental, caractere por caractere, explorando toda a árvore de espaço de estados.

Quando o algoritmo percebe que não pode tomar uma decisão definitiva sobre qual caractere incluir, ele se ramifica, testando todas as possibilidades viáveis e, recursivamente, volta atrás, fazendo o *backtrack* para comparar qual caminho gerou o melhor resultado.

Na implementação desenvolvida na classe LCSBacktracking, **a lógica central ocorre no método recursivo findLCS**. O algoritmo utiliza dois ponteiros independentes, *i* e *j*, para rastrear a posição atual na sequência *X* e na sequência *Y*, respectivamente. O processo de decisão obedece a três passos fundamentais:

```
private String findLCS(String x, String y, int i, int j) {  
    // registra o estado logo no início da recursão  
    metrics.registrarNovoEstado();  
  
    if (i == x.length() || j == y.length()) {  
        return "";  
    }  
  
    if (x.charAt(i) == y.charAt(j)) {  
        return x.charAt(i) + findLCS(x, y, i + 1, j + 1);  
    }  
  
    String caminhoA = findLCS(x, y, i + 1, j);  
    String caminhoB = findLCS(x, y, i, j + 1);  
  
    if (caminhoA.length() > caminhoB.length()) {  
        return caminhoA;  
    } else {  
        return caminhoB;  
    }  
}
```


Caso Base:

```
if (i == x.length() || j == y.length()) {  
    return "";  
}
```

A primeira verificação de qualquer recursão é sua condição de parada. Se o ponteiro *i* alcançar o final da string *X* ou se o ponteiro *j* alcançar o final da string *Y* (*i* == *x.length()* || *j* == *y.length()*), significa que não há mais caracteres para serem comparados em pelo menos uma das sequências. Nesse momento, o algoritmo retorna uma string vazia (""), encerrando aquele ramo da busca.

Caso Recursivo:

```
if (x.charAt(i) == y.charAt(j)) {  
    return x.charAt(i) + findLCS(x, y, i + 1, j + 1);  
}
```

Se a recursão não foi interrompida, o algoritmo compara os caracteres nas posições atuais de *X* e *Y*.

Se os caracteres nas posições *i* e *j* são iguais, então eles fazem parte de uma subsequência comum. Assim, o algoritmo:

- Salva esse caractere;
- Adiciona este caractere à solução e faz uma nova chamada recursiva avançando simultaneamente ambos os ponteiros (*i + 1* e *j + 1*).

Isso está correto porque respeita a definição de subsequência (mantendo a ordem).

O Backtracking na Prática:

O verdadeiro poder (e o maior custo) do algoritmo ocorre quando os **caracteres atuais são diferentes**. Como o computador não consegue prever qual

caractere deve ser descartado para maximizar os "matches" futuros, o *backtracking* se bifurca em dois caminhos distintos:

```
String caminhoA = findLCS(x, y, i + 1, j);  
String caminhoB = findLCS(x, y, i, j + 1);
```

Aqui, o algoritmo explora duas possibilidades:

- **Caminho A:** Ignora o caractere atual da *string* X e avança apenas o ponteiro i para o próximo caractere (i + 1, j).
- **Caminho B:** Ignora o caractere atual da *string* Y e avança apenas o ponteiro j para o próximo caractere (i, j + 1).

Após o processamento de ambos os caminhos até os seus respectivos casos base, o algoritmo compara o tamanho das duas soluções encontradas (**caminhoA.length() > caminhoB.length()**). Ele retorna a maior *string* originada dessa bifurcação, garantindo que o resultado final borbulhe até a raiz da árvore de recursão contendo a subsequência ótima.

```
if (caminhoA.length() > caminhoB.length()) {  
    return caminhoA;  
} else {  
    return caminhoB;  
}
```

Após o processamento de ambos os caminhos até os seus respectivos casos base, o algoritmo compara o tamanho das duas soluções encontradas. Ele retorna a maior *string* originada dessa bifurcação, garantindo que o resultado final borbulhe até a raiz da árvore de recursão.


3.1.1 Análise de Corretude

A corretude do algoritmo de *backtracking* para o problema LCS apoia-se em dois pilares fundamentais:

- **Propriedade de Subestrutura Ótima:** O algoritmo satisfaz a condição de que a LCS de duas *strings* maiores depende intrinsecamente da LCS de seus sufixos menores. O algoritmo resolve corretamente todos os subproblemas menores, independentemente de qual caminho seja tomado, e combina suas soluções de forma segura.
- **Exploração Completa (Busca Exaustiva):** A estratégia utilizada explora absolutamente toda a árvore de possibilidades do espaço de estados, exceto nos cenários onde há coincidência de caracteres (onde a bifurcação é desnecessária). Isso garante duas premissas vitais: nenhuma subsequência possível é ignorada durante o processamento, e a solução selecionada e retornada no final é, inquestionavelmente, a maior possível: **ótima global**.

3.1.2 Análise de Desempenho

3.1.2.1 Espacial



A complexidade de espaço teórica do algoritmo de *backtracking* sem memorização é $O(\max(n,m))$, onde n e m representam o comprimento das *strings* **X** e **Y**. Esse custo não se deve à criação de matrizes de dados, mas sim a


profundidade máxima alcançada pela Pilha de Chamadas Recursivas da *Java Virtual Machine* (JVM).

Durante a coleta de métricas, o consumo de memória RAM acompanhou o crescimento da árvore de estados, mas provou não ser o gargalo primário que inviabiliza o algoritmo. Para a entrada de 10 caracteres, o consumo foi praticamente irrisório, alocando apenas cerca de 450 KB. Ao dobrar a entrada para 20 caracteres, observou-se um salto para aproximadamente 70 MB (72.273 KB).

No teste extremo de 50 caracteres, até o momento em que a execução, limitada a 30 segundos no máximo, foi abortada compulsoriamente, o uso estabilizou-se na margem de 100 MB (102.514 KB). O aumento empírico no consumo de memória não causou o esgotamento total da RAM, devendo-se majoritariamente ao intenso processo de alocação de novas instâncias de *strings* geradas durante as concatenações de retorno da recursão.

3.1.2.2 Temporal

A análise temporal revela o verdadeiro gargalo estrutural desta abordagem. A complexidade de tempo do *backtracking* para o problema LCS no pior caso é de $O(2^k)$ (onde k é proporcional ao tamanho das sequências), resultante da natureza da árvore binária gerada pelas duas ramificações da recursão sempre que há uma disparidade de caracteres.



Os testes empíricos ilustram com exatidão o fenômeno da explosão combinatória. Para a entrada mínima de 10 caracteres, o tempo de execução foi de ínfimos 2 ms, exigindo a avaliação de 2.579 estados (nós da árvore). Contudo, ao dobrar o tamanho da entrada para 20 caracteres, o número de estados saltou agressivamente para 2.126.215 (mais de 2 milhões de ramificações exploradas), elevando o tempo de execução para 147 ms.

A prova cabal da falha de escalabilidade desta técnica ocorreu no teste da sequência de 50 caracteres, no qual a busca exaustiva tornou-se insustentável na prática. Em ensaios preliminares realizados sem a imposição de um limite temporal, a execução estendeu-se por mais de cinco minutos ininterruptos sem convergir para uma solução. Essa inviabilidade empírica evidenciou o travamento sistêmico causado pela explosão combinatória e motivou a implementação do mecanismo de interrupção segura (timeout) no motor de avaliação.

Ao reavaliar a entrada sob essa nova diretriz, a operação foi compulsoriamente abortada após exatos 30.001 milissegundos (30 segundos). Surpreendentemente, durante esse curto intervalo até o corte, o processador precisou avaliar a alta marca de 2.258.980.000 (mais de 2,2 bilhões) de estados sem chegar à resolução do problema.

Esse comportamento exponencial empírico ratifica a teoria: o *backtracking* puro explora implacavelmente o vasto espaço de busca, sendo computacionalmente inviável para amostras de dados reais (como sequências genéticas ou controle de versão de arquivos), justificando a necessidade imediata de técnicas de poda algorítmica.

3.2 Branch and Bound

A técnica do Branch and Bound surge como uma melhoria sobre a técnica do Backtracking tradicional, buscando reduzir o espaço de busca através da eliminação antecipada dos ramos que não podem levar as melhores soluções que a melhor já encontrada.

Enquanto o Backtracking explora toda a árvore de estados possíveis, o Branch and Bound adiciona o mecanismo de poda que é baseado em um limite superior o qual estima o melhor resultado que ainda pode ser obtido a partir de um determinado estado da busca.

Na implementação na classe *LCSBranchAndBound*, o algoritmo mantém duas informações principais:

- **current**: a subsequência comum contruída até o momento
- **bestLCS**: a melhor subsequência encontrada durante toda a execução.

```
public class LCSBranchAndBound implements LCSAlgorithm{
    //explora apenas ramos promissores, que podem melhorar a solucao
    private PerformanceMetrics metrics;
    private String bestLCS;

    public LCSBranchAndBound() {
        this.metrics = new PerformanceMetrics(30000);
    }

    public PerformanceMetrics getMetrics() {
        return metrics;
    }

    @Override
    public LCSResult solve(String x, String y) {

        this.metrics = new PerformanceMetrics(30000); //reinicia metrics
        bestLCS = ""; //iniciar com a melhor solucao (no momento sem subsequencia)

        if (x == null || y == null) {
            return new LCSResult(0, ""); //string nula = 0
        }

        branchAndBound(x, y, 0, 0, "");

        return new LCSResult(bestLCS.length(), bestLCS);
    }

    private void branchAndBound(String x, String y, int i, int j, String current) { //arvore de busca

        metrics.registrarNovoEstado(); //um estado da arvore de busca

        if (i == x.length() || j == y.length()) {

            if (current.length() > bestLCS.length()) { //se a solucao for melhor, atualiza
                bestLCS = current;
            }

            return;
        }

        int limiteSuperior = current.length() + Math.min(x.length() - i, y.length() - j); //tamanho max que o ramo pode alcançar
        //poda da arvorve:

        if (limiteSuperior <= bestLCS.length()) {
            return;
        }

        if (x.charAt(i) == y.charAt(j)) {

            branchAndBound(
                x,
                y,
                i + 1,
                j + 1,
                current + x.charAt(i)
            );
        } else {
            branchAndBound(x,y,i+1,j,current);

            branchAndBound(x,y,i,j+1,current);
        }
    }
}
```

A busca é realizada por meio de uma função recursiva que vai explorar os possíveis caminhos da árvore de estado, semelhante ao Backtracking. Porém, antes de expandir cada ramo, o algoritmo vai calcular um limite superior que representa o maior tamanho possível que a subsequência pode alcançar. O valor é calculado da seguinte forma:

```
int limiteSuperior = current.length() + Math.min(x.length() - i, y.length() - j); /
```

O valor obtido vai corresponder à soma entre: o tamanho da subsequência já construída (*current.length()*), e o número máximo de caracteres que ainda poderiam ser adicionados à solução.

Caso o limite superior seja menor ou igual ao tamanho da melhor solução já encontrada no *bestLCS*, o algoritmo interrompe a exploração daquele ramo da árvore de busca:

```
//poda da arvore:
if (limiteSuperior <= bestLCS.length()) {
    return;
}
```

Essa estratégia garante que os ramos incapazes de gerar melhores soluções sejam descartados imediatamente, reduzindo significativamente o número de estados explorados.

Quando os caracteres atuais das duas sequências são iguais, o algoritmo adiciona esse caractere à subsequência atual e avança em ambas as sequências. E caso contrário, o algoritmo vai explorar as duas possibilidades distintas: ignorar o caractere atual da primeira sequência ou ignorar o da segunda.

3.2.1 Análise de Corretude

A corretude do algoritmo Branch and Bound aplicado ao problema da sequência comum mais longa se fundamenta em três propriedades: na terminação da recursão (caso base), exploração adequada do espaço de busca (exploração dos casos) e na poda admissível.

Terminação (Caso Base):

A execução do algoritmo sempre termina pois a cada chamada recursiva pelo menos um dos índices que percorrem as sequências é incrementado.

Os parâmetros i e j representam as posições atuais nas sequências x e y , respectivamente. Como esses índices estão limitados pelos tamanhos das sequências, o número total de chamadas recursivas é finito. A execução atinge a condição base:

```
if (i == x.length() || j == y.length()) {  
    if (current.length() > bestLCS.length())  
        bestLCS = current;  
}  
  
return;
```

Quando satisfeita, significa que pelo menos uma das sequências foi totalmente percorrida e não existem mais caracteres que possam ser comparados. Nesse momento, a subsequência construída até então representa uma solução válida candidata a LCS.

Exploração do Espaço de Busca (Exploração dos casos)

Para garantir que nenhuma solução válida seja ignorada, o algoritmo considera todas as possibilidades relevantes de construção de subsequência, para caso os caracteres sejam iguais e quando não sejam iguais.

a) Quando os caracteres são iguais:

Quando os caracteres coincidem, estando nas posições atuais, eles podem fazer parte de uma subsequência comum. Nesse caso, o algoritmo adiciona esse caractere à solução atual e avança simultaneamente nas duas sequências. Esse comportamento está de acordo com a definição do problema do LCS, que mantém a ordem relativa dos caracteres nas duas sequências


```
if (x.charAt(i) == y.charAt(j)) {  
    branchAndBound( x,y,i + 1, j + 1, current + x.charAt(i));
```

b) Quando os caracteres são diferentes:

Já quando os caracteres não coincidem, ou seja são diferentes, estando nas posições atuais, o algoritmo explora duas possibilidades: ignorar o caractere atual da sequência X, ou ignorar o caractere atual da sequência Y.

Essa bifurcação vai garantir que todas as combinações relevantes das subsequências sejam analisadas, de forma semelhante ao comportamento do Backtracking.

```
} else {  
    branchAndBound( x, y,i + 1, j, current);  
    branchAndBound(x,y, i,j + 1,current);  
}
```

Estratégia de Poda (Branch and Bound)

O diferencial do algoritmo vai estar na aplicação da estratégia de poda baseada em limite superior. Esse limite representa o tamanho máximo que a subsequência atual poderia atingir considerando os caracteres restantes.

O cálculo é dado por:

```
int limiteSuperior = current.length() + Math.min(x.length() - i, y.length() - j);
```

Onde: **current** representa o tamanho da subsequência construída até o momento; e $n - i$ e $m - j$ representam os caracteres restantes de cada subsequência.

Condição de poda:

Se o valor do limite superior não for maior que o tamanho da melhor solução já encontrada então o algoritmo interrompe a exploração daquele ramo da árvore de busca. Essa poda pode ser considerada segura pois, até no melhor cenário possível, aquele ramo não poderia produzir uma subsequência maior do que a que já foi encontrada. Dessa forma, o ramo pode ser descartado sem comprometer a corretude da solução

```
//poda da arvore:  
if (limiteSuperior <= bestLCS.length()) {  
    return;  
}
```

Garantia de Otimalidade

Como todos os ramos que ainda possuem potencial de gerar soluções melhores são explorados, e apenas os ramos comprovadamente incapazes de superar a melhor solução são descartados, o algoritmo preserva a busca pela solução ótima.

Assim, ao final da execução, a variável **bestLCS** armazena necessariamente uma subsequência comum de comprimento máximo entre as duas sequências analisadas.

3.2.2 Análise de Desempenho

O algoritmo de *branch and bound* para o problema da LCS busca melhorar o desempenho em relação ao Backtracking puro, evitando explorar ramos que não podem gerar soluções melhores. Ainda assim, seu desempenho depende fortemente das entradas analisadas.

3.2.2.1 Espacial


O consumo de memória do algoritmo está principalmente relacionado a dois fatores: a pilha de recursão e o armazenamento das strings intermediárias (sequências). A complexidade espacial teórica do algoritmo Branch and Bound

permanece semelhante à do Backtracking, sendo dominada pela profundidade da pilha de chamadas recursivas.

A profundidade máxima da recursão ocorre quando os índices *i* e *j* avançam até o final das strings. No pior caso, isso resulta em uma profundidade de: **$O(n+m)$** , onde *n* e *m* são os tamanhos das strings (sequências) de entrada.

Além disso, o algoritmo utiliza a variável **current** para armazenar a subsequência que está sendo construída. Como as strings em Java são imutáveis, cada concatenação (**current + caractere**) cria uma nova string, o que pode aumentar o uso de memória ao longo da execução.

Branch and Bound - Memória em KB



Durante os testes, o consumo de memória apresentou crescimento moderado conforme o aumento do tamanho das entradas. Para sequências de 10 caracteres, o consumo foi de aproximadamente **450 KB**. Ao aumentar o tamanho das sequências para 20 caracteres, o consumo atingiu cerca de **27 MB (28.437 KB)**.

No teste com sequências de 50 caracteres, o consumo de memória reduziu para aproximadamente **5 MB (5.120 KB)**, o resultado pode ser explicado pela atuação da estratégia de poda, que diminuiu significativamente o número de estados explorados e consequentemente a quantidade de estruturas temporárias criadas durante a execução.

Assim, observa-se que apesar do crescimento da árvore de busca, o consumo de memória permaneceu dentro de limites razoáveis, não se configurando como o principal fator limitante da execução

3.2.2.2 Temporal


Do ponto de vista teórico, o algoritmo Branch and Bound ainda possui complexidade exponencial no pior caso, podendo ser aproximado por: $O(2^{n+m})$

Isso ocorre porque, em cenários desfavoráveis, a estratégia de poda pode não eliminar muitos ramos da árvore de busca, fazendo com que o algoritmo explore um número elevado de combinações possíveis.

Entretanto, na prática, a aplicação da poda reduz significativamente o número de estados visitados.

Os experimentos realizados mostram esse comportamento:

Branch and Bound - Tempo em ms



. Para a entrada contendo sequências de **10 caracteres**, o algoritmo executou em **1 ms**, explorando aproximadamente **2.260 estados** da árvore de busca.

Ao aumentar o tamanho das sequências para **20 caracteres**, o número de estados avaliados cresceu para cerca de **1.722.795**, resultando em um tempo de execução de **101 ms**.

Mesmo com esse crescimento expressivo, o algoritmo permaneceu capaz de encontrar a solução em tempo viável.

No teste com sequências de **50 caracteres**, o algoritmo avaliou aproximadamente **131.655 estados**, concluindo a execução em apenas **7 ms**.

Esse resultado evidencia o impacto positivo da estratégia de poda: grande parte da árvore de busca foi descartada antes de ser explorada, reduzindo drasticamente o trabalho computacional necessário para encontrar a solução ótima.

Comparando com o Backtracking, que explorou bilhões de estados sem conseguir resolver a instância de 50 caracteres dentro do limite de tempo estabelecido, observa-se uma melhora significativa no desempenho prático do Branch and Bound.

Essa diferença demonstra como a aplicação de limites superiores na exploração do espaço de busca pode transformar um algoritmo teoricamente exponencial em uma solução viável para entradas maiores.

3.3 Programação Dinâmica

A Programação Dinâmica (PD) apresenta-se como a solução algorítmica definitiva para o gargalo temporal evidenciado na Busca Exaustiva. A essência desta estratégia consiste em subverter o problema da sobreposição de subproblemas através da memorização.

Em vez de recalcular estados repetidos em uma árvore de recursão, o algoritmo armazena os resultados parciais em uma estrutura de dados, trocando intencionalmente o consumo de espaço (memória) por uma drástica redução no tempo de execução.

Na implementação desenvolvida, o problema é resolvido de forma iterativa (*bottom-up*) dividida em duas fases fundamentais: o preenchimento da matriz de estados e o rastreamento reverso para a construção da *string*.

Fase 1: Preenchimento da Matriz de Memorização

A primeira etapa consiste em inicializar uma matriz bidimensional *dp* de dimensões $(m+1) \times (n+1)$, onde *m* e *n* representam os comprimentos das *strings* *X* e *Y*. Cada célula *dp*[*i*][*j*] armazenará o comprimento da Maior Subsequência Comum encontrada até aqueles respectivos índices.

```
int[][] dp = new int[m + 1][n + 1];

// Preenchimento da tabela
for (int i = 1; i <= m; i++) {
    for (int j = 1; j <= n; j++) {

        metrics.registrarNovoEstado();

        if (x.charAt(i - 1) == y.charAt(j - 1)) {
            dp[i][j] = dp[i - 1][j - 1] + 1;
        } else {
            dp[i][j] = Math.max(dp[i - 1][j], dp[i][j - 1]);
        }
    }
}
```

A lógica de transição de estados baseia-se na propriedade de subestrutura ótima do problema, onde a solução para as sequências maiores é construída de forma incremental, aproveitando as soluções já calculadas para os seus prefixos menores:

1. **Se os caracteres coincidem ($x.charAt(i - 1) == y.charAt(j - 1)$):** O caractere atual faz parte da LCS. A célula atual herda o valor da célula em sua diagonal superior esquerda (que representa o tamanho da LCS calculado exatamente antes da inclusão dessas duas letras) acrescido de 1 (**$dp[i - 1][j - 1] + 1$**).
2. **Se os caracteres diferem:** O caractere não compõe a LCS naquele alinhamento simultâneo. A célula atual deve simplesmente carregar o melhor resultado obtido até o momento. Para isso, ela assume o valor máximo entre o resultado ignorando o caractere atual da *string* *X* (célula superior: **$dp[i -$**

`dp[i][j]`) e o resultado ignorando o caractere atual da *string* Y (célula à esquerda: `dp[i][j - 1]`).

Fase 2: Reconstrução da Subsequência (Rastreamento Reverso)

Após o preenchimento completo, o canto inferior direito da matriz (`dp[m][n]`) contém o **comprimento máximo** da LCS. No entanto, para resgatar a *string* em si, é necessário realizar um caminho de volta (*backtracking* iterativo) pelos estados armazenados.

```
// Reconstrução da LCS
StringBuilder lcs = new StringBuilder();
int i = m, j = n;

while (i > 0 && j > 0) {
    metrics.registrarNovoEstado();

    if (x.charAt(i - 1) == y.charAt(j - 1)) {
        lcs.append(x.charAt(i - 1));
        i--;
        j--;
    } else if (dp[i - 1][j] > dp[i][j - 1]) {
        i--;
    } else {
        j--;
    }
}

return new LCSResult(lcs.length(), lcs.reverse().toString());
}
```

O algoritmo posiciona os ponteiros no fim de ambas as *strings* e navega pela matriz de forma reversa. Sempre que os caracteres das sequências originais coincidem, a letra é anexada ao resultado (uma vez que originou um incremento na diagonal). Caso sejam diferentes, o algoritmo avalia qual dos vizinhos (superior ou esquerdo) possui o maior valor e move o ponteiro em direção a ele, refazendo o caminho ótimo. Como a leitura é feita do fim para o início, o construtor `StringBuilder` utiliza o método `reverse()` no momento de encapsular e retornar o `LCSResult` final.

3.3.1 Análise de Corretude

A corretude do algoritmo de Programação Dinâmica fundamenta-se na exploração matemática completa do espaço de soluções, sem qualquer perda de otimalidade.

Diferente da Estratégia Gulosa (que faz escolhas locais precipitadas), a matriz dp garante que todas as combinações de prefixos possíveis entre as *strings* X e Y sejam avaliadas e comparadas.

Ao preencher a matriz utilizando a propriedade de subestrutura ótima, o algoritmo garante que o valor depositado na última célula ($dp[m][n]$) é matematicamente e inquestionavelmente o tamanho máximo da LCS global.

A reconstrução da *string* a partir do rastreamento reverso desta matriz apenas transcreve os passos ótimos que levaram a esse valor máximo, assegurando 100% de exatidão na resposta final.

3.3.2 Análise de Desempenho


A Programação Dinâmica demonstrou ser a abordagem mais equilibrada e escalável para o problema da Maior Subsequência Comum (LCS). Ao contrário das abordagens exaustivas, a PD mantém uma previsibilidade de execução que permitiu processar 10.000 caracteres em milissegundos.

```
INICIANDO ANÁLISE COM: PROGRAMAÇÃO DINÂMICA
=====
>> Testando arquivo: inputs/lcs_100_chars.txt
Comprimento da LCS: 76
LCS: GATTACAAGCTAAAAGATTACAACTAACGATTCAGGTACTGAGTATGGATTCTGAGTATGGATTCTGAGTATG
Tempo de Execução: 1 ms
Uso de Memória: 901 KB (0 MB)
Estados Avaliados (Iterações na Matriz): 10124
-----
>> Testando arquivo: inputs/lcs_1000_chars.txt
Comprimento da LCS: 950
LCS: ATGCGTAGCTAGCTAGCTAGCATGCATGCATGCATGCATGCATGCATGCATGCATGCATGCATGCATGCATGCATGCATGCATGCATGCATGCATGCATGCATGC... [Omitido por ser muito longa]
Tempo de Execução: 20 ms
Uso de Memória: 3979 KB (3 MB)
Estados Avaliados (Iterações na Matriz): 999999
-----
>> Testando arquivo: inputs/lcs_10000_chars.txt
Comprimento da LCS: 1250
LCS: GAIAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAAA... [Omitido por ser muito longa]
Tempo de Execução: 45 ms
Uso de Memória: 15861 KB (15 MB)
Estados Avaliados (Iterações na Matriz): 4000749
-----
=== COMPARATIVO LCS ===
```


3.3.2.1 Espacial

O consumo de memória na Programação Dinâmica é ditado pela alocação da matriz de estados. A complexidade teórica é $O(nm)$. Nos testes realizados, observamos o seguinte comportamento:

- **100 caracteres:** O uso de memória foi de **901 KB**, refletindo uma matriz pequena (101x101).
- **1.000 caracteres:** O consumo subiu para **3.979 KB (~3 MB)**.
- **10.000 caracteres:** Para a maior instância, o uso de memória atingiu **15.861 KB (~15 MB)**.



Embora o crescimento seja quadrático em relação à entrada, a implementação mostrou-se eficiente o suficiente para que, mesmo com 10.000 caracteres, o consumo permaneça em patamares baixos para sistemas modernos, não ultrapassando 16 MB. Vale ressaltar que o número de estados avaliados (iterações na matriz) para a maior instância foi de aproximadamente 4 milhões. Isso


demonstra que o tempo de execução e o consumo de memória estão diretamente atrelados ao produto dos comprimentos das duas sequências fornecidas ($M \times N$), e não apenas ao limite superior de caracteres de um único arquivo.

3.3.2.2 Temporal

A análise temporal da abordagem por Programação Dinâmica confirma a drástica quebra na barreira da explosão combinatória evidenciada no Backtracking, apresentando uma complexidade estritamente polinomial ($O(M \times N)$), onde M e N são os comprimentos das sequências.

Nos testes realizados, observamos o seguinte comportamento:

- **Instâncias Pequenas (~100x100 caracteres):** A execução foi instantânea, levando apenas **1 ms**.
- **Instâncias Médias (~1.000x1.000 caracteres):** O tempo de execução cresceu proporcionalmente para **20 ms**, mantendo-se perfeitamente viável.
- **Instâncias Grandes (~10.000 caracteres):** No teste de estresse com arquivos de 10.000 caracteres, a execução foi concluída em apenas **45 ms**.



Este tempo de 45 ms é surpreendentemente rápido para uma matriz de 10.000 x 10.000 (que conteria 100 milhões de estados). Uma análise mais detalhada dos dados do terminal revela a razão para essa eficiência excepcional: o número de 'Estados Avaliados' para esta instância foi de **4.000.749**, indicando que as strings de entrada resultaram em uma matriz de operações significativamente menor do que 100 milhões.

O tempo de 45 ms é perfeitamente condizente com o processamento de aproximadamente 4 milhões de estados (complexidade $O(10,000 \times 400)$), consolidando a Programação Dinâmica como a solução escalável por excelência para o problema LCS, desde que o produto dos comprimentos das strings permaneça dentro dos limites de memória.

3.4 Estratégia Gulosa

A Estratégia Gulosa (*Greedy Approach*) foi implementada na classe LCSGreedy como uma alternativa heurística de alta velocidade.

O princípio fundamental desta abordagem é a tomada de decisões ótimas locais a cada passo, com a esperança de que essas escolhas conduzam a uma solução ótima global. Diferente da Programação Dinâmica, que avalia todas as possibilidades futuras antes de decidir, o algoritmo Guloso é irreversível: uma vez que um caractere é escolhido para compor a subsequência, ele nunca mais é reconsiderado.

A implementação da estratégia é iterativa e extremamente eficiente em termos de processamento, pois não utiliza tabelas de memorização ou recursão pesada. O algoritmo utiliza dois ponteiros (*i* e *j*) para percorrer as *strings* de entrada de forma sequencial.

```

StringBuilder lcs = new StringBuilder();
int j = 0;

for (int i = 0; i < x.length(); i++) {

    int buscaJ = j;

    while (buscaJ < y.length()) {
        metrics.registrarNovoEstado();

        if (x.charAt(i) == y.charAt(buscaJ)) {
            lcs.append(x.charAt(i));
            j = buscaJ + 1;
            break;
        }
        buscaJ++;
    }
}

```

O funcionamento segue a seguinte lógica:

1. O algoritmo tenta encontrar o primeiro caractere da *string* X que também esteja presente na *string* Y, a partir da posição atual do ponteiro de Y.
2. **Se encontrar uma correspondência:** A letra é adicionada à LCS e os dois ponteiros avançam irreversivelmente para a próxima posição.
3. **Se não encontrar:** O algoritmo simplesmente descarta o caractere atual de X e avança para o próximo.

Essa pressa em aceitar a primeira correspondência que aparece pela frente é o que confere ao algoritmo uma velocidade impressionante, mas é também o que o impede de garantir que o resultado final será a *maior* subsequência possível.

3.4.1 Análise de Corretude

Diferente das abordagens anteriores, a Estratégia Gulosa **não garante a corretude** para o problema da Maior Subsequência Comum. A sua falha reside na "miopia algorítmica": ao aceitar a primeira correspondência que encontra, o

algoritmo pode fixar um caractere que, embora correto individualmente, bloqueia o acesso a uma cadeia muito maior de alinhamentos subsequentes.

Para provar essa limitação, foi realizado um teste de estresse utilizando sequências de 10.000 caracteres com uma estrutura de "longa distância":

- **Cenário de Teste:** A *string* X inicia com o caractere 'G' seguido de uma vasta sequência de caracteres 'A' e padrões de bases nitrogenadas (TGCGT...). A *string* Y contém a mesma sequência de 'A's e bases nitrogenadas, mas o caractere 'G' só aparece na última posição.
- **O Erro da Heurística:** O algoritmo Guloso identifica o 'G' no início de X e varre a *string* Y até encontrá-lo na última posição. Ao fixar este 'G' como o primeiro elemento da LCS, o ponteiro de busca em Y é movido para o final da sequência. Como resultado, o algoritmo encerra a execução prematuramente, pois não restam mais caracteres em Y para serem comparados com o restante de X.

Enquanto a Programação Dinâmica foi capaz de ignorar o 'G' inicial para alinhar os outros **9.999** caracteres (alcançando o ótimo global), a Estratégia Gulosa retornou um comprimento de apenas **1**. Este experimento comprova que a pressa da heurística em aceitar decisões locais a torna inadequada para problemas onde a solução ótima depende do contexto global das sequências.


3.4.2 Análise de Desempenho

A análise de desempenho da Estratégia Gulosa confirma sua natureza de algoritmo de alta performance e baixo consumo de recursos, apresentando resultados que superam todas as outras técnicas em velocidade e economia de memória.

3.4.2.1 Espacial

O desempenho espacial da Estratégia Gulosa representa o limite inferior de consumo de memória entre todas as abordagens analisadas. Diferente da Programação Dinâmica, que exige uma complexidade de espaço $O(n \times m)$ para

sustentar a matriz de memorização, e do *Backtracking*, que demanda $O(n+m)$ para a pilha de chamadas recursivas, a Estratégia Gulosa opera em **espaço adicional constante $O(1)$** .



Os testes empíricos demonstram essa eficiência:

- **100 caracteres:** O uso de memória foi de **684 KB**. Este valor, ligeiramente superior aos demais testes gulosos, reflete o *overhead* inicial da JVM e o carregamento das bibliotecas de métricas no primeiro teste da bateria.
- **1.000 caracteres:** O consumo caiu para apenas **38 KB**, evidenciando que o algoritmo não escala o uso de memória conforme a entrada cresce.
- **10.000 caracteres:** Mesmo na maior instância, o consumo permaneceu em **45 KB**, um valor insignificante que representa apenas as variáveis de controle e a construção da *string* de retorno.

Essa economia extrema ocorre porque a estratégia não utiliza estruturas auxiliares complexas, processando as sequências de forma puramente iterativa.


3.4.2.2 Temporal

A análise temporal da Estratégia Gulosa confirma sua complexidade linear $O(n + m)$, sendo a única abordagem capaz de processar grandes volumes de dados de forma quase instantânea.

Os resultados coletados mostram a disparidade de tempo em relação à Programação Dinâmica:

- **100 e 1.000 caracteres:** O algoritmo registrou **0 ms**, indicando que a execução ocorreu em um tempo menor do que a precisão de milissegundos do sistema.
- **10.000 caracteres:** Mesmo na instância massiva de teste, o tempo foi de apenas **1 ms**.

Enquanto a Programação Dinâmica realizou 4 milhões de iterações para processar os 10.000 caracteres em 45 ms, a estratégia gulosa precisou de apenas 1.999 avanços de ponteiro para concluir a mesma tarefa em 1 ms. Este desempenho temporal excepcional justifica o uso da heurística em sistemas que demandam respostas imediatas, desde que a precisão absoluta (corretude) não seja o requisito primário.



A discrepância entre os resultados da Estratégia Gulosa (501) e da Programação Dinâmica (1.250) para a instância de 10.000 caracteres é uma consequência direta da **natureza assimétrica e repetitiva** do pacote de entrada fornecido.

A entrada em questão inicia com um caractere isolado ('**G**') seguido por um bloco maciço de repetições ('**A**') e padrões complexos de bases nitrogenadas. A Estratégia Gulosa falha em encontrar o melhor resultado global por conta de dois fatores principais observados neste pacote:

- **A "Armadilha" do Primeiro Caractere:** Caso o caractere inicial '**G**' da String X encontre uma correspondência em uma posição tardia na String Y, o algoritmo guloso irá realizar o casamento imediatamente. Como os ponteiros de busca nunca retrocedem, o algoritmo "descarta" involuntariamente todo o bloco de caracteres anteriores na String Y que poderiam fazer parte de uma subsequência muito maior.
- **Decisões Locais Precipitadas:** O pacote de entrada possui muitos caracteres repetidos ('AAAA...'). O algoritmo guloso aceita a primeira ocorrência que visualiza. Se uma subsequência ótima global exigisse que o algoritmo "esperasse" para casar um caractere de X com uma posição específica mais à frente em Y para preservar outros alinhamentos, a Estratégia Gulosa seria incapaz de fazê-lo.

4 EXPERIMENTOS E RESULTADOS

4.1 Instâncias de Teste

Para garantir a reprodutibilidade e a precisão dos experimentos, o sistema foi avaliado utilizando um conjunto de instâncias de teste padronizadas, armazenadas em arquivos de texto (**.txt**) dentro do diretório de recursos do projeto.

Inspirando-se em aplicações reais do problema da Maior Subsequência Comum na área de bioinformática, as *strings* de entrada foram modeladas simulando sequências de DNA, compostas exclusivamente pelos caracteres representativos das bases nitrogenadas: A (Adenina), C (Citosina), G (Guanina) e T (Timina).

Foram definidos três cenários de complexidade crescente para submeter os algoritmos ao estresse computacional:

- **Cenário 1 (Tamanho 10):** Arquivo **lcs_10_chars.txt**, contendo duas sequências curtas de 10 caracteres cada.
- **Cenário 2 (Tamanho 20):** Arquivo **lcs_20_chars.txt**, com sequências de 20 caracteres.
- **Cenário 3 (Tamanho 50):** Arquivo **lcs_50_chars.txt**, contendo sequências maiores de 50 caracteres.
- **Cenário 4 (Tamanho 100):** Arquivo **lcs_100_chars.txt**, marcando a transição onde o *Backtracking* começa a se tornar inviável.
- **Cenário 5 (Tamanho 1.000):** Arquivo **lcs_1000_chars.txt**, para testar a eficiência da Programação Dinâmica em larga escala.
- **Cenário 6 (Tamanho 10.000):** Arquivo **lcs_10000_chars.txt**, contendo a estrutura de estresse "G...AAAA" para validar a falha de corretude da Estratégia Gulosa e a robustez espacial da Programação Dinâmica.

Essa variação amostral foi escolhida estrategicamente não apenas para validar a corretude das saídas, mas principalmente para demonstrar na prática o fenômeno da explosão combinatória e testar os limites de escalabilidade das estratégias implementadas.

4.2 Resultados Obtidos

Os experimentos foram conduzidos em um ambiente de *benchmark* controlado, utilizando o motor de análise desenvolvido na classe **Main**. Antes da execução de cada instância, a JVM foi instruída a executar a limpeza de memória (*Garbage Collector*) para evitar contaminação nas medições de consumo espacial.

Tabela 1: Resultados empíricos da execução do algoritmo de Backtracking

Arquivo de Entrada	Tamanho da Entrada	Comprimento	Tempo de Execução	Memória	Nós
lcs_10_chars.txt	10 caracteres	4	2 ms	450 KB (0 MB)	2.579
lcs_20_chars.txt	20 caracteres	9	147 ms	72.273 KB (70 MB)	2.126.215
lcs_50_chars.txt	50 caracteres	N/A (Abortado)	30.001 ms (Corte)	102.514 KB (100 MB)	2.258.980.000

A Tabela 1 apresenta o compilado dos dados brutos obtidos durante a execução do algoritmo de *Backtracking* puro. As métricas englobam o comprimento da solução ótima encontrada, o custo temporal, a alocação dinâmica de memória RAM e a quantidade exata de ramificações (estados) exploradas na árvore de busca.

Tabela 2: Resultados empíricos da execução do algoritmo de Branch and Bound.

Arquivo de Entrada	Tamanho da Entrada	Comprimento	Tempo de Execução	Memória	Nós
lcs_10_chars.txt	10 caracteres	4	1 ms	450 KB (0 MB)	2.260
lcs_20_chars.txt	20 caracteres	9	101 ms	28437 KB (27 MB)	1.722.795
lcs_50_chars.txt	50 caracteres	41	7 ms	5120 KB (5 MB)	131.655

A Tabela 2 expõe os resultados empíricos coletados após a execução do algoritmo otimizado de *Branch and Bound* sobre o mesmo conjunto de instâncias. Com a devida instrumentação do motor de avaliação, foi possível rastrear a quantidade de nós explorados, permitindo uma medição exata do impacto da heurística de poda sobre a redução do espaço de busca.

Tabela 3: Resultados empíricos da execução do algoritmo de Programação Dinâmica.

Arquivo de Entrada	Tamanho da Entrada	Comprimento	Tempo de Execução	Memória	Nós
lcs_100_chars.txt	100 caracteres	76	1 ms	901 KB	10.124
lcs_1000_chars.txt	1000 caracteres	950	20 ms	3.979 KB	999.999
lcs_10000_chars.txt	10.000 caracteres	1.250	45 ms	15.861 KB	4.000.749

Diferente das abordagens recursivas, a Programação Dinâmica demonstrou uma complexidade polinomial. Mesmo na instância de 10.000 caracteres, onde os algoritmos anteriores falhariam por exaustão de tempo, a PD concluiu a tarefa em ínfimos 45 ms, provando ser a única estratégia capaz de garantir o ótimo global em tempo polinomial.

Tabela 4: Resultados empíricos da execução do algoritmo de Estratégia Gulosa.

Arquivo de Entrada	Tamanho da Entrada	Comprimento	Tempo de Execução	Memória	Nós
lcs_100_chars.txt	100 caracteres	60	0 ms	684 KB	100
lcs_1000_chars.txt	1000 caracteres	950	0 ms	38 KB	1.000
lcs_10000_chars.txt	10.000 caracteres	501	1 ms	45 KB	1.999

A Estratégia Gulosa apresentou os melhores tempos de execução e o menor consumo de memória adicional (espaço auxiliar). Contudo, a análise de corretude na instância de 10.000 caracteres revela sua limitação crítica: enquanto a PD encontrou uma LCS de 1.250, a Heurística retornou apenas 501, evidenciando o sacrifício da otimalidade em prol da velocidade.

A consolidação dos dados brutos apresentados nestas quatro tabelas revela o comportamento prático de cada paradigma algorítmico frente ao aumento progressivo da carga de processamento. Observa-se uma **clara linha divisória na escalabilidade**: enquanto os métodos baseados em busca exaustiva (**Backtracking** e **Branch and Bound**) limitaram-se à execução bem-sucedida apenas das instâncias iniciais (**10, 20 e 50 caracteres**), atingindo rapidamente barreiras intransponíveis de tempo e memória, as abordagens otimizadas (**Programação Dinâmica** e **Estratégia Gulosa**) demonstraram robustez para manter a operabilidade mesmo em escalas de **10.000 caracteres**.

5 ANÁLISE E DISCUSSÃO

Análise e discussão a respeito das técnicas de algoritmos Backtracking e Branch and Bound e uma comparação na sua aplicação.

5.1 Comparação das Estratégias

A análise comparativa entre os algoritmos de Backtracking e Branch and Bound evidencia diferenças significativas no comportamento computacional das duas abordagens quando aplicadas ao problema da Maior Subsequência Comum (LCS).

O algoritmo de Backtracking realiza uma exploração completa do espaço de busca, avaliando todas as combinações possíveis de subsequências que podem ser formadas a partir das duas sequências analisadas. Essa estratégia garante a obtenção da solução ótima, porém apresenta um custo computacional mais elevado. Como observado nos experimentos realizados, o número de estados explorados cresce de forma exponencial com o aumento do tamanho das sequências de entrada.

Nos testes realizados com sequências de 10 caracteres, o algoritmo apresentou desempenho satisfatório, avaliando pouco mais de dois mil estados e concluindo a execução em poucos milissegundos. Entretanto, ao aumentar o tamanho das sequências para 20 caracteres, o número de estados explorados ultrapassou dois milhões, evidenciando o crescimento explosivo da árvore de busca.

No caso mais extremo, com sequências de 50 caracteres, o algoritmo não conseguiu concluir a execução dentro do limite de tempo estipulado, tendo sido interrompido após explorar mais de dois bilhões de estados.

Este comportamento demonstra uma limitação prática do Backtracking para instâncias de maior porte, tornando a abordagem inviável em aplicações reais que envolvem sequências extensas.

Por outro lado, o algoritmo Branch and Bound introduz um mecanismo de poda baseado em limite superior, permitindo descartar antecipadamente ramos da árvore de busca que não possuem potencial para gerar soluções melhores do que a

já encontrada. Essa estratégia reduz significativamente o número de estados explorados durante a execução.

Os resultados experimentais demonstram o impacto dessa otimização. Para sequências de 10 caracteres, o comportamento do algoritmo permanece semelhante ao Backtracking, pois o espaço de busca ainda é relativamente pequeno. No entanto, à medida que o tamanho das sequências aumenta, a eficiência da poda torna-se evidente.

No teste com sequências de 20 caracteres, embora o número de estados explorados ainda seja elevado, o algoritmo foi capaz de concluir a execução em tempo viável. Já no cenário mais complexo, com sequências de 50 caracteres, o Branch and Bound apresentou desempenho significativamente superior ao Backtracking, avaliando apenas 131.655 estados e concluindo a execução em poucos milissegundos.

Esse resultado evidencia que a estratégia de poda foi capaz de eliminar grande parte da árvore de busca antes mesmo de sua exploração completa. Em particular, a presença de blocos de similaridade entre as sequências permitiu que uma solução inicial de boa qualidade fosse encontrada rapidamente, elevando o valor de referência utilizado para o cálculo do limite superior e intensificando o processo de poda.

Dessa forma, observa-se que, embora ambos os algoritmos tenham complexidade exponencial no pior caso, o Branch and Bound apresenta desempenho significativamente superior na prática, tornando-se uma alternativa mais eficiente para a resolução do problema da LCS em instâncias de maior dimensão.

Enquanto as abordagens exaustivas sucumbem à medida que as sequências de DNA se tornam minimamente extensas, a **Programação Dinâmica (PD)** apresenta-se como a solução definitiva para a escalabilidade do problema LCS. A grande diferença reside na técnica de **memorização**, que substitui o recálculo redundante de subproblemas — presente no *Backtracking* — pelo armazenamento sistemático em uma matriz de estados.

Diferente do crescimento exponencial observado anteriormente, a PD demonstrou uma estabilidade de tempo polinomial $O(nxm)$. Nos experimentos, essa eficiência foi traduzida em números impressionantes: a instância de **10.000 caracteres**, que seria computacionalmente impossível para o *Backtracking*, foi resolvida em apenas **45 ms**.

Entretanto, essa performance temporal impõe um custo espacial. Como discutido na análise de desempenho, a necessidade de alocar uma matriz proporcional ao produto dos comprimentos das *strings* resultou em um consumo de aproximadamente **15 MB** de memória RAM. Embora esse valor seja perfeitamente manejável em hardware moderno, ele evidencia o *trade-off* fundamental desta estratégia: sacrifica-se o espaço de armazenamento para garantir que o tempo de execução permaneça viável e que a solução ótima global seja invariavelmente encontrada.

A **Estratégia Gulosa** introduz uma perspectiva distinta ao problema, priorizando a velocidade de execução acima da garantia de corretude absoluta. Por operar com uma complexidade linear $O(n + m)$, ela foi, sem surpresa, a abordagem mais rápida de todos os testes, processando a instância máxima em apenas **1 ms** e utilizando uma quantidade desprezível de memória adicional (**45 KB**).

Contudo, os testes com o cenário de estresse revelaram a fragilidade desta heurística. Ao tomar decisões ótimas locais (casar caracteres assim que são encontrados), o algoritmo exibe uma "miopia" que o impede de visualizar alinhamentos futuros mais vantajosos. O resultado prático foi contundente:

- **Programação Dinâmica:** Encontrou uma LCS de **1.250** caracteres.
- **Estratégia Gulosa:** Retornou uma LCS de apenas **501** caracteres.

Essa disparidade de mais de **150%** no resultado final demonstra que, para problemas de alta sensibilidade como o alinhamento de sequências genéticas, a velocidade da Estratégia Gulosa não compensa a perda de precisão, tornando-a inadequada quando a otimalidade é um requisito crítico.

Ao confrontar as quatro estratégias, observa-se que o problema da Maior Subsequência Comum serve como um excelente laboratório para o estudo de

complexidade de algoritmos. O **Backtracking** e o **Branch and Bound** representam a força bruta e a força bruta otimizada, respectivamente; ambos são matematicamente corretos, mas limitados a amostras pequenas de dados.

A **Programação Dinâmica** consolida-se como o padrão-ouro para aplicações reais, pois rompe a barreira exponencial com um custo de memória previsível e aceitável. Já a **Estratégia Gulosa** posiciona-se no extremo oposto: é uma ferramenta de altíssima performance para aproximações rápidas, mas falha no objetivo primordial de encontrar a *maior* subsequência possível, provando que o caminho mais curto na árvore de decisões raramente leva ao topo da montanha do ótimo global.

Estratégia	Complexidade Tempo	Complexidade Espaço	Garante Ótimo?
Backtracking	$O(2^{n+m})$	$O(n+m)$	Sim
Branch and Bound	$O(2^{n+m})$	$O(n+m)$	Sim
Programação Dinâmica	$O(nm)$	$O(nm)$	Sim
Gulosa	$O(n+m)$	$O(1)$	Não

6 CONCLUSÃO

A análise realizada neste trabalho permitiu analisar o comportamento de duas técnicas clássicas de projeto de algoritmos aplicadas ao problema da Maior Subsequência Comum (LCS): o Backtracking e o Branch and Bound.

Inicialmente, foi implementado o algoritmo de Backtracking, que realiza uma busca exaustiva sobre o espaço de estados do problema. Essa abordagem garante a obtenção da solução ótima, pois explora todas as combinações possíveis de subsequências. No entanto, os experimentos demonstraram que essa estratégia apresenta crescimento exponencial no número de estados explorados, tornando-se rapidamente inviável à medida que o tamanho das sequências aumenta.

Em seguida, foi implementada uma versão utilizando a técnica de Branch and Bound, que apresenta um mecanismo de poda baseado em limite superior para eliminar antecipadamente ramos que não podem levar a soluções melhores. A aplicação dessa estratégia mostrou-se altamente eficaz na redução do espaço de busca, permitindo que o algoritmo evitasse a exploração de grande parte da árvore de estados.

Os resultados experimentais evidenciaram claramente essa diferença de comportamento. Enquanto o Backtracking não foi capaz de resolver a instância de 50 caracteres dentro do limite de tempo estabelecido, o algoritmo Branch and Bound conseguiu encontrar a solução ótima em poucos milissegundos, explorando uma fração muito menor do espaço de busca.

Adicionalmente, a implementação da **Programação Dinâmica** representou o ápice da eficiência e corretude neste estudo. Ao substituir a busca exaustiva pela técnica de memorização, foi possível transpor a barreira exponencial, resolvendo instâncias de **10.000 caracteres** com um custo temporal de apenas **45 ms**. Este resultado confirma que a complexidade polinomial $O(nm)$ é a única viável para aplicações em larga escala que exigem precisão absoluta.

Esses resultados demonstram que a utilização de técnicas de poda pode transformar significativamente o desempenho prático de algoritmos exponenciais, tornando possível resolver instâncias maiores de problemas combinatórios.

Por outro lado, a **Estratégia Gulosa** evidenciou o dilema fundamental da computação: o sacrifício da otimalidade em prol da performance extrema. Embora tenha apresentado execução quase instantânea (1 ms) e consumo mínimo de memória, sua incapacidade de encontrar a maior subsequência comum em cenários de alta complexidade (obtendo 501 caracteres contra os 1.250 da PD) reforça que heurísticas devem ser aplicadas com cautela, sendo restritas a contextos onde a velocidade supera a necessidade de exatidão.

Em suma, os experimentos realizados demonstram que não existe um algoritmo universalmente superior, mas sim escolhas baseadas em restrições. Enquanto o **Backtracking** e o **Branch and Bound** servem como bases teóricas e soluções para pequenos volumes, a **Programação Dinâmica** se consagra como o padrão-ouro para sistemas de bioinformática e processamento de dados reais, equilibrando de forma magistral o uso de memória e a velocidade de resposta.

7 REFERÊNCIAS

CORMEN, T. H. et al. **Algoritmos: Teoria e Prática**. 3. ed. Rio de Janeiro: Elsevier, 2012.

FEOFILOFF, P. **Subsequência comum máxima**. São Paulo: Instituto de Matemática e Estatística da Universidade de São Paulo (IME-USP). Disponível em: https://www.ime.usp.br/~pf/analise_de_algoritmos/aulas/lcs.html

GUIMARÃES, N. **Algoritmos Gulosos**. Belo Horizonte: Departamento de Ciência da Computação da UFMG. Disponível em: <https://homepages.dcc.ufmg.br/~nvilela/algoritmos/greedy.pdf>

OFFOLO, Tiago A. M. **Backtracking**. Ouro Preto: Universidade Federal de Ouro Preto, Departamento de Computação. Disponível em: https://www3.decom.ufop.br/toffolo/site_media/uploads/2011-1/bcc402/slides/10._backtracking.pdf

SANTOS, Maristela Oliveira dos. **Branch and Bound**. São Carlos: Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, 2011. Disponível em: <https://sites.icmc.usp.br/mari/segundo2011/Aula0711.pdf> >

UNIVERSIDADE FEDERAL DE OURO PRETO. **Branch and Bound**. Departamento de Computação. Ouro Preto: UFOP. Disponível em: http://www.decom.ufop.br/gustavo/bcc342/Branch_and_bound_livro.pdf

WAGNER, Aldo von. **Backtracking**. Florianópolis: Universidade Federal de Santa Catarina. Disponível em: <https://www.inf.ufsc.br/~aldo.vw/Analise/Backtracking.html>